Clasificación de la ejecución de un ejercicio de rehabilitación mediante una CNN temporal

Comparación con regresión logística en IntelliRehabDS

Trabajo práctico de Redes Neuronales y Deep Learning
Maestría en Inteligencia Artificial · Universidad de Palermo

Laura Daniela Muñoz Torres · Anna Carla · Carlos Catán · Jonathan Caceres Prada

Versión tras devolución docente · 7 de octubre de 2026
Visto bueno docente recibido. Nombres completos y enlace al repositorio por confirmar.

Resumen

Evaluamos si una CNN temporal mejora la clasificación de la etiqueta global de ejecución correcta o incorrecta del gesto 2 de IntelliRehabDS frente a regresión logística. Trabajamos con 369 secuencias de 26 participantes y validación cruzada agrupada por persona. La CNN recibió coordenadas tridimensionales de Kinect; la logística utilizó 15 características construidas a partir del movimiento y la duración.

En la ejecución corregida, la exactitud balanceada media fue 0,873 para la CNN y 0,917 para la logística. Al restringir el análisis a pacientes, fue 0,666 y 0,816, respectivamente. La red no aportó una mejora puntual y su resultado fue más variable entre semillas. Estas diferencias describen el experimento y no prueban superioridad universal de un método.

Pregunta y criterio de éxito

La pregunta fue qué desempeño logra una red temporal al evaluar personas que no participaron en su entrenamiento, y si su complejidad aporta una ventaja respecto de un método sencillo. El criterio académico fue implementar, comparar y explicar el proceso con trazabilidad; no maximizar una cifra sin examinar cómo se obtuvo.

Qué haríamos con más tiempo

La prioridad sería fortalecer los datos y la evaluación: equilibrar ejecuciones correctas e incorrectas por persona, revisar la definición de etiqueta y evaluar en un conjunto externo. También estudiaríamos la calibración del umbral de la CNN y la estabilidad de sus particiones. Más épocas, por sí solas, no resuelven estos problemas. Esta evaluación técnica no valida una herramienta clínica ni su uso con cámara doméstica.

Datos y delimitación del problema

IntelliRehabDS contiene posiciones tridimensionales del esqueleto registradas con Kinect y anotaciones de corrección de ejercicios. El depósito describe anotación independiente por dos personas y permite descargar SkeletonData.zip. Usamos la versión pública 2.0.1 y citamos su descriptor asociado [1]. La unidad de análisis es una secuencia completa; sus fotogramas no se tratan como observaciones independientes.

Paso de selección	Secuencias	Personas
Gesto 2 antes de exclusiones	376	28
Excluir grabación interrumpida	370	27
Conservar etiquetas 1 y 2	369	26

Codificamos la etiqueta publicada 1 como correcta y la 2 como incorrecta; incorrecta es la clase positiva del clasificador. La etiqueta 3 queda fuera del análisis binario. El aviso del depósito justifica la exclusión de una grabación interrumpida. La etiqueta es global: no identifica una compensación específica, una causa neurológica ni una indicación de tratamiento.

Por qué este subconjunto

Acotar el experimento a un gesto permitió estudiar una tarea binaria manejable dentro del curso. El gesto 2 se describe como flexión anterior de hombro. La revisión previa observó discrepancias entre el nombre lateral del gesto y el brazo que se mueve; por eso lo denominamos gesto 2 del dataset sin adjudicar lado anatómico. No transferimos estas etiquetas a ejercicios distintos ni al prototipo de cámara.

Población analizada	Correctas	Incorrectas	Total
A Todos	223	146	369
B Solo pacientes	70	146	216

Todas las secuencias incorrectas provienen de pacientes. Los 14 controles aportan 153 secuencias, todas correctas, y tres pacientes concentran 121 de las 146 incorrectas. Esto permite que características de persona, postura o registro se asocien con la etiqueta. El análisis B y el comparador estático examinan esa dependencia, pero no identifican causalmente qué señales utiliza cada modelo.

Preparación de entradas

Cada fotograma tiene 25 articulaciones por tres coordenadas. Centramos las coordenadas en la base de la columna y dividimos por una longitud de tronco calculada dentro de cada secuencia. Interpolamos a 64 pasos temporales, obteniendo una matriz de 75 canales por 64 pasos. El logaritmo del número de fotogramas entra por separado: es una aproximación a duración, no segundos medidos, y puede reflejar diferencias de captura.

Diseño de evaluación y comparación

Usamos StratifiedGroupKFold para mantener juntas todas las repeticiones de una persona. La estratificación intenta preservar las clases, pero la agrupación y el tamaño reducido pueden impedirlo [2]. Un reparto aleatorio de secuencias podría dejar a una misma persona en entrenamiento y prueba, facilitando una estimación demasiado optimista.

Etapa	Función	Decisiones permitidas
Prueba externa	5 particiones en A y 4 en B	Medir desempeño en personas excluidas del entrenamiento externo
Validación interna	3 particiones dentro del entrenamiento externo	Elegir regularización, época y umbral
Repeticiones	Semillas 0, 1 y 2	Examinar variación de particiones e inicialización

Cada secuencia recibe una predicción externa por semilla; las métricas principales reúnen esas predicciones. No reservamos un test fijo durante todo el desarrollo. Los cambios posteriores a observar resultados no constituyen confirmación independiente. Las semillas reutilizan personas: no equivalen a tres estudios.

Regresión logística y control estático

La logística usa seis características de cada brazo: máximo, mínimo y rango de elevación, mínimo y media del ángulo del codo, y media absoluta de la segunda diferencia temporal de elevación. Se añaden máximo y rango de inclinación del tronco y logaritmo del número de fotogramas. La segunda diferencia no es una aceleración física en unidades de tiempo.

StandardScaler se ajusta solo en entrenamiento. Se prueban C = 0,01; 0,1; 1 y 10 con ponderación de clases. La selección usa AUC de predicciones internas fuera de muestra; luego se ajusta la logística sobre todo el entrenamiento externo. El control estático usa el primer fotograma del esqueleto normalizado por secuencia y la misma familia de clasificador. No modela una trayectoria, aunque la escala de normalización usa información de la secuencia completa.

Métricas e incertidumbre

La métrica principal es exactitud balanceada: promedio de sensibilidad a incorrectas y especificidad a correctas. Informamos F1 y AUC para complementar la lectura. Media y desviación estándar se calculan entre semillas a partir de métricas agrupadas; no son intervalos de confianza. Para semilla 0 se estiman intervalos percentiles del 95 % con 2.000 remuestreos de participantes, omitiendo remuestras con una sola clase.

Una prueba externa de B contiene seis secuencias correctas. Sensibilidad y exactitud balanceada binaria no son estimables: el resumen usa 11/12 folds en B y 15/15 en A. Las métricas agrupadas por semilla conservan todas las secuencias y ambas clases.

Arquitectura y decisiones de entrenamiento

Exploramos convoluciones temporales porque permiten aprender patrones locales en la evolución de las coordenadas sin definir manualmente todos los descriptores. Dos bloques y 22.594 parámetros mantienen el experimento pequeño. La comparación con logística evalúa si esta representación aprendida aporta valor. No se usó preentrenamiento: se trabajó con coordenadas y una red pequeña; transfer learning no era obligatorio y no se evaluó un modelo preentrenado compatible.

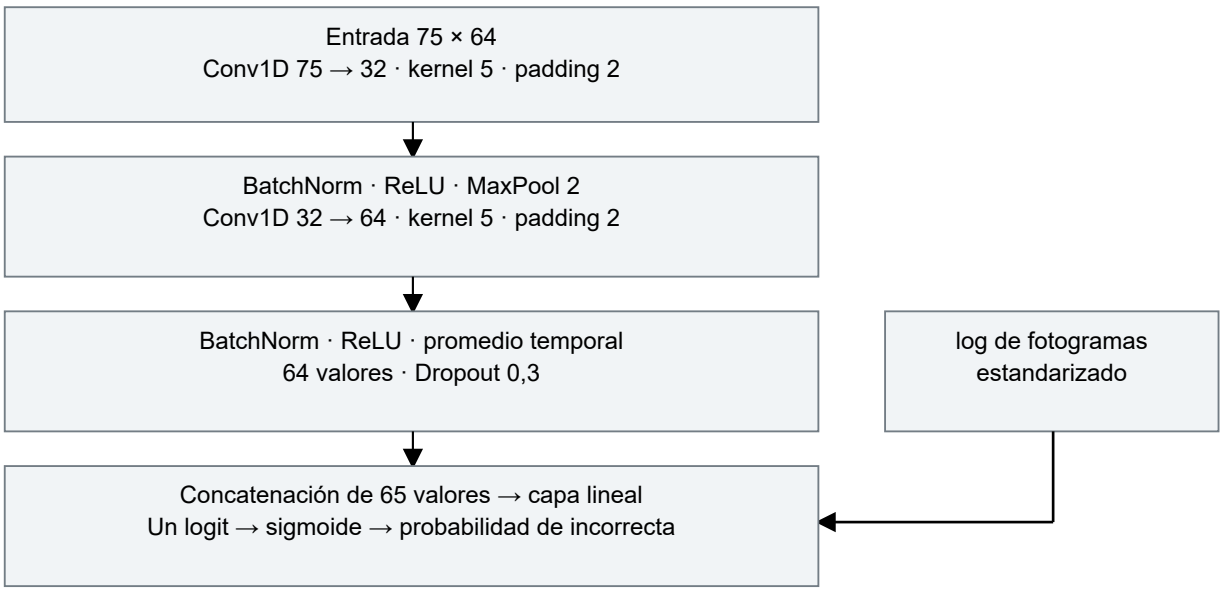


Figura 1. Arquitectura de cada modelo interno. La evaluación CNN promedia probabilidades de tres modelos internos; los pesos de demo con todos los datos no son el modelo evaluado.

Entrenamos con Adam, tasa 0,001, weight decay 0,0001, lotes de hasta 32 y un máximo de 60 épocas. La pérdida de entrenamiento es BCEWithLogitsLoss con peso positivo igual a negativas/positivas del entrenamiento. Dropout y penalización de pesos buscan limitar el ajuste excesivo. Las estadísticas por canal y del logaritmo de duración se ajustan exclusivamente con el subconjunto que entrena cada modelo.

Elegimos la época de menor pérdida media de validación interna. Se entrenan las 60 épocas y se recuperan los estados guardados de la época seleccionada: no se detiene anticipadamente el entrenamiento. El umbral maximiza sensibilidad + especificidad sobre predicciones internas fuera de muestra. Después promediamos las probabilidades externas de los tres modelos internos usando su propia normalización.

Hay una limitación de diseño: el umbral se aprende con una predicción interna por secuencia, mientras que la prueba utiliza un promedio de tres modelos. Esa diferencia puede afectar la calibración. La red tampoco se reentrena sobre todo el entrenamiento externo, a diferencia de la logística; la comparación representa estos procedimientos concretos.

Curvas y lectura del aprendizaje

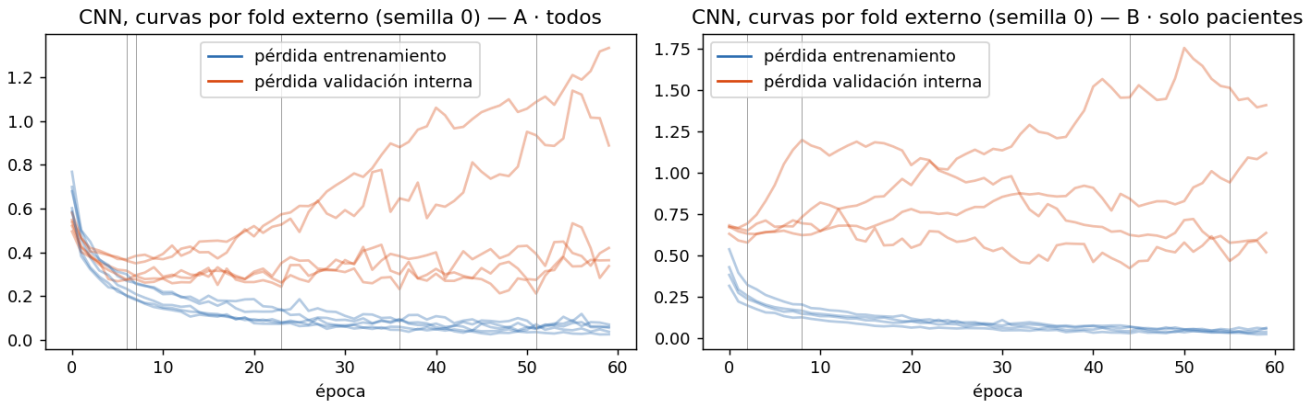


Figura 2. Curvas guardadas de la ejecución corregida, semilla 0. Cada par de líneas resume el entrenamiento y la validación internos de una partición externa. La abscisa empieza en cero: x = 0 equivale a la primera época.

Partición externa	A Todos	B Pacientes
1	24	56
2	37	45
3	7	9
4	8	3
5	52	No aplica

La pérdida de entrenamiento disminuye en todas las particiones. En varias curvas, la pérdida de validación mejora al inicio y luego aumenta, mientras entrenamiento continúa descendiendo. Este patrón es compatible con sobreajuste. Otras particiones mantienen validación más estable y eligen épocas posteriores. No hay una época óptima única para todos los grupos.

En B la validación presenta diferencias pronunciadas entre particiones. Las épocas seleccionadas van de 3 a 56 en la semilla mostrada. Con pocas personas y una distribución desigual de etiquetas, cambiar quién queda en cada grupo altera la dificultad del problema. Las curvas justifican seleccionar épocas por validación; no justifican aumentar el entrenamiento hasta obtener una cifra deseada.

Qué se puede comparar en la figura

El entrenamiento pondera clases y la validación utiliza pérdida no ponderada. Por eso su diferencia vertical no es una medida directa de generalización y se retiró del notebook un cálculo que la presentaba como tal. La interpretación se apoya en la evolución de cada curva y en las métricas externas, no en restar dos objetivos distintos.

La corrección de normalización afectó la inferencia externa, no las trayectorias internas ya entrenadas. Por ello la imagen de curvas coincide con la del archivo previo mientras las métricas CNN cambian. La trazabilidad exige conservar figuras, código y resultados con una identificación de versión clara.

Alcance de la selección

La época y el umbral se seleccionan sin utilizar las etiquetas del test externo para esa decisión. Sin embargo, la revisión del experimento sí observó resultados de versiones anteriores. Una futura estimación confirmatoria debe reservar datos externos nuevos, además de preservar la separación por persona.

Resultados de la ejecución corregida

Análisis y modelo	Exactitud balanceada	Sensibilidad	F1 incorrecta	AUC
A Estático	0,733 ± 0,016	0,651 ± 0,022	0,673 ± 0,020	0,817 ± 0,071
A Logística	0,917 ± 0,010	0,959 ± 0,020	0,892 ± 0,013	0,969 ± 0,001
A CNN	0,873 ± 0,038	0,852 ± 0,094	0,844 ± 0,045	0,952 ± 0,022
B Estático	0,552 ± 0,121	0,386 ± 0,232	0,473 ± 0,227	0,600 ± 0,064
B Logística	0,816 ± 0,025	0,817 ± 0,040	0,857 ± 0,021	0,894 ± 0,045
B CNN	0,666 ± 0,092	0,523 ± 0,159	0,634 ± 0,140	0,804 ± 0,051

Tabla 1. Media ± desviación estándar poblacional entre semillas 0, 1 y 2; valores entre 0 y 1. Cada semilla agrupa las predicciones externas de todas sus secuencias. A incluye 369 secuencias de 26 personas; B, 216 secuencias de 12 pacientes.

La logística obtiene mayor exactitud balanceada puntual en A y B. La diferencia CNN menos logística es −0,043 en A y −0,150 en B. La sensibilidad CNN en B es 0,523 frente a 0,817 de la logística: bajo estos umbrales, la red deja sin detectar más etiquetas incorrectas. No interpretamos los resultados como porcentajes de pacientes beneficiados ni como capacidad clínica validada.

El control estático alcanza 0,733 en A y 0,552 en B. Esto muestra que una entrada sin trayectoria temporal puede clasificar parte de las etiquetas del conjunto completo. El resultado es compatible con asociaciones entre condición de participante y etiqueta; no permite atribuir causalmente el desempeño a una señal específica. B cambia composición y tamaño de muestra, por lo que la caída entre A y B tampoco aísla un único efecto.

Modelo y análisis	IC 95 % de exactitud balanceada para semilla 0
A Logística	0,819 a 0,954
A CNN	0,672 a 0,948
B Logística	0,692 a 0,902
B CNN	0,383 a 0,787

Tabla 2. Intervalos descriptivos por bootstrap de participantes sobre predicciones externas fijas. No reentrenan el modelo en cada remuestra ni son intervalos de la diferencia entre modelos. Su amplitud señala incertidumbre; no se infiere significación a partir de su solapamiento.

Los resultados detallados y las métricas complementarias se conservan en resultados_agregados.json. El archivo llama pr_auc al cálculo average_precision_score; debe leerse como precisión promedio y no como integración trapezoidal de la curva precisión–recobrado.

Variación entre particiones y referencia reciente

Tras la devolución docente se incorporó el benchmark de Zhu, Xiang y Tian [4]. Reporta 2.575 secuencias de 29 personas y usa validación externa por sujeto con StratifiedGroupKFold. Comparte la separación de participantes con este TP, pero no es una réplica: trabaja con varios gestos y una cohorte diferente.

El artículo selecciona configuraciones mediante macro-F1 interno, utiliza umbral fijo 0,50 y reajusta sobre el entrenamiento externo. Nuestro TP selecciona AUC para logística y pérdida para épocas CNN, ajusta umbral interno por Youden y promedia modelos internos de CNN. Por tanto, sus cifras no son una referencia numérica directamente comparable ni el origen retrospectivo de nuestras decisiones. La referencia se conoció después de ejecutar el experimento.

La tabla siguiente responde a la solicitud de media y desvío entre particiones. Se calcula por separado dentro de cada semilla. Así no se confunde variación de folds con la variación entre semillas de las métricas agrupadas de la tabla principal. Cada fold recibe el mismo peso; al tener tamaños distintos, el promedio no coincide necesariamente con la métrica sobre todas las predicciones reunidas.

Modelo	Semilla	F1 incorrecta	AUC	Folds F1/AUC
A Logística	0	0,568 ± 0,465	0,939 ± 0,095	5/5
A Logística	1	0,839 ± 0,121	0,980 ± 0,015	5/5
A Logística	2	0,796 ± 0,186	0,964 ± 0,027	5/5
A CNN	0	0,542 ± 0,355	0,928 ± 0,071	5/5
A CNN	1	0,750 ± 0,193	0,965 ± 0,020	5/5
A CNN	2	0,672 ± 0,358	0,944 ± 0,050	5/5
B Logística	0	0,646 ± 0,290	0,853 ± 0,064	4/4
B Logística	1	0,866 ± 0,078	0,907 ± 0,078	4/4
B Logística	2	0,888 ± 0,094	0,948 ± 0,038	3/3
B CNN	0	0,528 ± 0,270	0,867 ± 0,093	4/4
B CNN	1	0,441 ± 0,309	0,871 ± 0,082	4/4
B CNN	2	0,780 ± 0,185	0,875 ± 0,113	3/3

Tabla 3. Media ± DE poblacional (ddof = 0) entre folds externos. A tiene cinco folds por semilla; B, cuatro. En B semilla 2 hay tres folds con ambas clases: F1 positiva y AUC no estimables en el restante. No se tratan las 15 o 12 particiones repetidas como estudios independientes.

La dispersión entre folds muestra que el desempeño depende de qué personas quedan en prueba. No se modifica el entrenamiento después de esta devolución. Las nuevas tablas son análisis descriptivos de las predicciones externas ya guardadas.

Resultados exploratorios por posición

Se vincularon índices de predicción con los archivos originales ordenados, comprobando identidad de participante y etiqueta. Las categorías se conservan literalmente: chair, stand, wheelchair, sit y Stand-frame. No se fusionaron sit y chair ni stand y Stand-frame sin una equivalencia documentada. Estas posiciones no se utilizaron para volver a entrenar o seleccionar umbrales.

Análisis y posición	Personas	Correctas / incorrectas	F1 logística / CNN	AUC logística / CNN
A Stand-frame	1	4/2	0,000 / 0,679	0,792 / 0,792
A chair	12	81/52	0,911 / 0,783	0,994 / 0,931
A sit	2	12/0	N/D / N/D	N/D / N/D
A stand	18	101/14	0,884 / 0,766	0,998 / 0,986
A wheelchair	5	25/78	0,890 / 0,884	0,937 / 0,919
B Stand-frame	1	4/2	0,000 / 0,167	0,958 / 0,667
B chair	2	21/52	0,754 / 0,210	0,870 / 0,832
B stand	5	20/14	0,849 / 0,551	0,964 / 0,825
B wheelchair	5	25/78	0,924 / 0,815	0,908 / 0,867

Tabla 4. Medias de métricas calculadas por posición en cada una de las tres semillas, sobre predicciones externas agrupadas. A: todos; B: pacientes. La desviación entre semillas, sensibilidad, especificidad y exactitud balanceada constan en resultados_por_posicion.csv. Los conteos de personas pueden solaparse entre posiciones y no deben sumarse como participantes distintos.

La distribución de etiquetas cambia mucho con la posición: wheelchair reúne 78 incorrectas y 25 correctas, mientras stand en A reúne 14 y 101. sit solo contiene ejecuciones correctas: no se puede estimar detección de incorrectas ni AUC. La ausencia de estimación se muestra como N/D, no como cero.

Dentro de pacientes, chair contiene 73 secuencias de solo dos personas y Stand-frame, seis secuencias de una persona. El F1 de la CNN en B es 0,210 en chair y 0,815 en wheelchair. Estas diferencias pueden reflejar composición de participantes, etiquetas y registro; no demuestran un efecto causal de la posición ni permiten recomendar el modelo para un subgrupo clínico.

Este análisis se añadió de forma exploratoria después de la sugerencia docente. Para una evaluación futura se requiere planificar combinaciones de persona, posición y clase con soporte suficiente y verificar su generalización en datos nuevos. La aprobación comunicada respalda la continuidad del TP; no sustituye esta limitación metodológica.

Dificultades correcciones y aprendizajes

Una red más compleja no produjo una mejora

La hipótesis explorada no obtuvo apoyo en la comparación puntual: la CNN quedó por debajo de la logística, especialmente en pacientes. El tamaño y la composición del conjunto, la representación de entrada y el procedimiento de ensamblado son explicaciones posibles, no causas demostradas. La respuesta fue analizar curvas, grupos y errores, conservando el resultado desfavorable en lugar de seleccionar otra ejecución por conveniencia.

Normalización distinta entre entrenamiento e inferencia

La revisión del código detectó que los modelos internos se entrenaban con estadísticas de su propio subconjunto, pero al predecir se normalizaba con todo el entrenamiento externo. No implicaba usar el test para ajustar esas estadísticas; sí cambiaba la transformación que recibía cada modelo. Se corrigió para reutilizar el mismo subconjunto de referencia de cada modelo interno, se vaciaron las salidas antiguas y se solicitó una ejecución nueva. El informe usa solo el ZIP corregido del 5 de octubre.

Una clase ausente no significa sensibilidad cero

En una partición de B no había ejemplos incorrectos. La división protegida contra cero devolvía sensibilidad cero y exactitud balanceada 0,5 aunque todas las seis predicciones fueran correctas. Se cambió a no estimable y se informó el número de particiones válidas. La exactitud balanceada agrupada por semilla sigue siendo estimable y no se excluyeron esas secuencias del resultado global.

Resultados guardados que pertenecían a versiones diferentes

El notebook recibido y el primer ZIP tenían cifras CNN distintas, aunque coincidían sus épocas seleccionadas. Esa coincidencia no probaba identidad de ejecución. Se retiraron tablas históricas del texto activo y se exportaron etiquetas, probabilidades y predicciones para verificar los cálculos de la nueva versión. Esta auditoría aritmética no reemplaza una reproducción independiente del entrenamiento.

Plan de mejora priorizado

Primero, datos y etiquetas. Reunir más personas con ambas clases, documentar mejor el ejercicio y las razones de incorrección, y mantener un conjunto externo. Para una aplicación clínica futura, acordar una referencia profesional independiente antes de recoger datos.

Después, evaluación y modelo. Comprobar viabilidad de clases en cada partición, comparar reentrenamiento y ensamblado bajo reglas predefinidas, estudiar calibración del umbral y contrastar la contribución de duración. Cualquier control posterior debe identificarse como exploratorio y no incorporarse retrospectivamente a la hipótesis inicial.

Finalmente, transferencia de dominio. La eventual cámara doméstica tiene otro sensor, esqueleto y condiciones. Se necesitarían correspondencia de entradas, nuevas etiquetas y evaluación específica. No basta con cargar los pesos Kinect en una aplicación con MediaPipe.

Reproducibilidad conclusiones y referencias

La ejecución de referencia declara Python 3.13.15, NumPy 2.1.3, scikit-learn 1.6.1, PyTorch 2.11.0+cpu y Matplotlib 3.10.0; usa CPU y semillas 0, 1 y 2. El README describe la carga de SkeletonData.zip en Colab, su comprobación MD5, la ejecución ordenada y la exportación. Las versiones son las registradas en el artefacto, no una garantía de equivalencia entre equipos.

Se verificaron independientemente 72 valores resumen de seis métricas, sus matrices y umbrales externos, cobertura de participantes y seis conjuntos de intervalos bootstrap desde las predicciones del ZIP. No se reentrenó localmente. El notebook de código está incluido sin salidas; queda incorporar la copia guardada de la ejecución corregida y comprobar el entorno de reproducción en una sesión limpia.

Los pesos de demo entrenados con todos los datos no tienen evaluación independiente. La carpeta contiene resultados agregados; los datos se obtienen del depósito. Quedan por completar la URL del repositorio y la revisión de autores.

Conclusión

Una CNN temporal pequeña permitió completar un experimento de clasificación con evaluación por persona, pero no mejoró los valores puntuales de la regresión logística. El resultado más útil fue identificar los límites de la representación, la distribución de etiquetas y la trazabilidad del procedimiento. La complejidad del modelo exige una comparación verificable; no constituye por sí misma una ventaja.

Referencias y materiales consultados

[1] Miron A, Sadawi N, Grosan C, Ismail W, Hussain H. IntelliRehabDS, versión 2.0.1. Zenodo, 2021. DOI 10.5281/zenodo.4610859. Licencia CC BY 4.0 verificada en los metadatos del depósito. Depósito y archivo SkeletonData.zip. Descriptor asociado: Miron A et al. IntelliRehabDS (IRDS)—A Dataset of Physical Rehabilitation Movements. Data. 2021;6(5):46. DOI 10.3390/data6050046. Referencia bibliográfica indicada por el depósito; no se basan aquí afirmaciones adicionales en su texto completo.

[2] scikit-learn. StratifiedGroupKFold. Documentación oficial. Consulta de la documentación disponible el 5 de octubre de 2026; el experimento usa scikit-learn 1.6.1, no necesariamente la versión actual del sitio.

[3] Código fuente TP_Redes_DL.ipynb y resultados de la revisión 2026-10-05_normalizacion_interna_metricas_clase_ausente. ZIP original de referencia: resultados_TP_IRDS (1).zip. SHA-256: 426c61299748c28e175a79ab901b7e3794d408647dbc052ca030a8de796dcbb7.

[4] Zhu Z, Xiang Y, Tian X. Skeleton-based rehabilitation movement quality classification: a leakage-controlled benchmark on IntelliRehabDS. Frontiers in Medicine. 2026;13:1878438. DOI 10.3389/fmed.2026.1878438. Artículo consultado el 7 de octubre por recomendación docente.

Pendientes de revisión de autores

Confirmar nombres académicos y contribuciones; revisar y adoptar la narrativa; incorporar notebook ejecutado; publicar repositorio y comprobar acceso; completar registro de entrega; el visto bueno docente ya fue recibido. Se usaron herramientas de IA para apoyar programación, revisión y redacción. Las responsabilidades y la revisión final corresponden a los integrantes. No se atribuye al grupo una búsqueda bibliográfica exhaustiva ni validación clínica.